

## Agenda:

- + multivariate Ableitungen (verschiedene Noten)
- + Kettenregel mit der Anwendung in Kl.
- Höhere Ableitungen
- Multivariate Optimierung

Wir haben eine Abbildung  $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$  (Der Definitionsbereich kann auch eine Teilmenge von  $\mathbb{R}^n$  sein; Einfachheit halber hier  $\mathbb{R}^n$ ).

$$f(x) = f(x_1, \dots, x_n) = \begin{bmatrix} f_1(x_1, \dots, x_n) \\ f_2(x_1, \dots, x_n) \\ \vdots \\ f_m(x_1, \dots, x_n) \end{bmatrix}$$

Fall  $m=1$ :  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  Funktionen in  $n$  Variablen  $x_1, \dots, x_n$

Fall  $m=n$ : Eine (nichtlineare) Transformation des Raums  $\mathbb{R}^n$ .

Die Jacobi-Matrix, bezieht als  $J_f(x)$  oder  $f'(x)$

oder 
$$\frac{\partial (f_1, f_2, \dots, f_m)}{\partial (x_1, x_2, \dots, x_n)} :$$

$$\begin{array}{c} \textcircled{f_1} \\ \vdots \\ \textcircled{f_m} \end{array} \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m}{\partial x_1} & \dots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

$\textcircled{\frac{\partial}{\partial x_1}} \qquad \qquad \qquad \textcircled{\frac{\partial}{\partial x_n}}$

Die Absicht: Die kleine Änderung von  $f$ ,

$\Delta f := f(x + \Delta x) - f(x)$  zu approximieren  
als  $f'(x) \cdot \Delta x$ .

$\Delta x$  ist der Vektor der Änderungen der Variablen

$$\Delta x = \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix}.$$

Unter welcher Bedingung hat man die Approximation?

Es reicht aus, dass alle partiellen Ableitungen

$$\frac{\partial f_i}{\partial x_j} : \mathbb{R}^n \rightarrow \mathbb{R} \quad \text{stetig sind} \quad \begin{matrix} (i = 1, \dots, m \\ j = 1, \dots, n) \end{matrix}$$

In diesem Fall hat man:

$$\Delta f = f'(x) \cdot \Delta x + o(\Delta x), \quad \text{für } \Delta x \rightarrow 0.$$

Oder anders formuliert:

$$f(x + \Delta x) = f(x) + f'(x) \cdot \Delta x + o(\Delta x),$$

für  $\Delta x \rightarrow 0$ .

Oder so formuliert:

$$f(x) = f(x^*) + f'(x^*) \cdot (x - x^*) + o(x - x^*),$$

für  $x \rightarrow x^*$ .

Bei  $m=1$  ist  $f'(x) = \left( \frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_n} \right)$  — eine Zeile

von der Gradient

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix} \quad \text{— eine Spalte}$$

(kein großer Unterschied).

Bsp

$$f(x_1, x_2) = x_1 \cos(x_2 - x_1^2)$$

$$\begin{cases} x_1 \rightsquigarrow x \\ x_2 \rightsquigarrow y \end{cases}$$

$$f(x, y) = x \cos(y - x^2)$$

$$\nabla f(x, y) = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

$$\frac{\partial f}{\partial x} = \cos(y - x^2) + x \cdot (2x \cdot \sin(y - x^2))$$

↓  
Produktregel

$$\frac{\partial f}{\partial y} = -x \sin(y - x^2)$$

Wir setzen  $(x^*, y^*) = (1, -1)$


$$f(x, y) \approx f(x^*, y^*)$$

$$+ \frac{\partial f}{\partial x}(x^*, y^*) \cdot (x - x^*) + \frac{\partial f}{\partial y}(x^*, y^*) \cdot (y - y^*)$$

bei  $x \approx x^*,$   
 $y \approx y^*$

$$\left\langle \nabla f(x^*, y^*), \begin{pmatrix} x \\ y \end{pmatrix} - \begin{pmatrix} x^* \\ y^* \end{pmatrix} \right\rangle$$

In Richtung von  $\nabla f(x^*, y^*)$  steigt man  
 lokal am schnellsten




### Bemerkung zum Gradienten

Cauchy Schwarz Besatz:

$$|\langle u, x \rangle| \leq \|u\| \cdot \|x\|$$

mit der Gleichung genau dann wenn  
 $x$  und  $u$  linear unabhängig sind.  
 $(x, u \in \mathbb{R}^n)$

$$-\|u\| \cdot \|x\| \leq \langle u, x \rangle \leq \|u\| \cdot \|x\|$$



Wenn wir  $x$  variieren, aber  $\|x\|$  festhalten,  
 so kriegen wir bei  $\langle u, x \rangle$  den größten Wert,  
 wenn  $x$  die Richtung von  $u$  hat, z.B.  $x = \frac{u}{\|u\|}$ .

Und wir kriegen den niedrigsten Wert, wenn  
x die Richtung von  $-u$  hat.

$\leadsto \nabla f$  ist die Richtung des schnellsten  
Anstiegs von  $f$  (lokal)

$-\nabla f$  ist die Richtung des schnellsten  
Abstiegs von  $f$  (lokal).

Antwort ist  $\nabla f(p)$  (lokal) senkrecht zur  
Niveau-Fläche  $\{x : f(x) = f(p)\}$   
( $p$  - der fixierte Punkt).

### Kettenregel

$f(g(x))$  muss abgeleitet werden.

$$\begin{array}{ccccc} \mathbb{R}^k & \xleftarrow{f} & \mathbb{R}^m & \xleftarrow{g} & \mathbb{R}^n \\ \downarrow \psi & & \downarrow \psi & & \downarrow \psi \\ f(y) = f(g(x)) & & y = g(x) & & x \end{array}$$

$$\underbrace{f(g(x))'}_{k \times n} = \underbrace{f'(g(x))}_{k \times m} \cdot \underbrace{g'(x)}_{m \times n}$$


Oder so:

$$J_{f \circ g}(x) = J_f(g(x)) \cdot J_g(x)$$

Bsp.

$$f(x,y) = x \cos(y - x^2).$$

$$g(r,\varphi) = \begin{bmatrix} r \cos \varphi \\ r \sin \varphi \end{bmatrix}$$



$$f = x \cos(y - x^2)$$

$$x = r \cos \varphi$$

$$y = r \sin \varphi$$

$$\begin{cases} \frac{\partial f}{\partial r} = \frac{\partial f}{\partial x} \cdot \frac{\partial x}{\partial r} + \frac{\partial f}{\partial y} \cdot \frac{\partial y}{\partial r} \\ \frac{\partial f}{\partial \varphi} = \frac{\partial f}{\partial x} \cdot \frac{\partial x}{\partial \varphi} + \frac{\partial f}{\partial y} \cdot \frac{\partial y}{\partial \varphi} \end{cases}$$

$$\begin{bmatrix} \frac{\partial f}{\partial r} \\ \frac{\partial f}{\partial \varphi} \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} \begin{bmatrix} \frac{\partial x}{\partial r} \\ \frac{\partial y}{\partial r} \end{bmatrix}$$

Hier Bezeichnungen vernachlässigt:  
 $x, y$  sind gleichzeitig Variablen und Funktionen.  
 $f$  hat gleichzeitig zwei Bedeutungen.

Aber man schreibt so in der Physik (z.B.).

$$\frac{\partial x}{\partial r} = \frac{\partial}{\partial r} r \cos \varphi = \cos \varphi$$

$$\frac{\partial y}{\partial r} = \frac{\partial}{\partial r} r \sin \varphi = \sin \varphi$$

$$\frac{\partial x}{\partial \varphi} = \frac{\partial}{\partial \varphi} r \cos \varphi = -r \sin \varphi$$

$$\frac{\partial y}{\partial \varphi} = \frac{\partial}{\partial \varphi} r \sin \varphi = r \cos \varphi$$

$$\Rightarrow \frac{\partial f}{\partial r} = \frac{\partial f}{\partial x} \cdot \cos \varphi + \frac{\partial f}{\partial y} \cdot \sin \varphi$$

$$\frac{\partial f}{\partial \varphi} = \frac{\partial f}{\partial x} \cdot (-r \sin \varphi) + \frac{\partial f}{\partial y} \cdot (r \cos \varphi)$$

$\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}$  haben wir bereits ausgerechnet.

$$f(x, y)$$

$$X = r \cos \varphi$$

$$Y = r \sin \varphi$$

$$X(r, \varphi)$$

$$Y(r, \varphi)$$

$$f(r \cos \varphi, r \sin \varphi) = f(X, Y) = f(X(r, \varphi), Y(r, \varphi))$$

$$f(X, Y) \leftarrow \begin{pmatrix} X \\ Y \end{pmatrix} \leftarrow \begin{pmatrix} r \\ \varphi \end{pmatrix}$$

$$\frac{\partial}{\partial r} f(X, Y) = \left( \frac{\partial f}{\partial x} \right)(X, Y) \cdot \frac{\partial X}{\partial r} + \left( \frac{\partial f}{\partial y} \right)(X, Y) \cdot \frac{\partial Y}{\partial r}$$

$$\frac{\partial}{\partial \varphi} f(X, Y) = \left( \frac{\partial f}{\partial x} \right)(X, Y) \cdot \frac{\partial X}{\partial \varphi} + \left( \frac{\partial f}{\partial y} \right)(X, Y) \cdot \frac{\partial Y}{\partial \varphi}$$

Das Gleiche mit Matrizen

$$\underbrace{\begin{bmatrix} \frac{\partial}{\partial r} f(X, Y) & \frac{\partial}{\partial \varphi} f(X, Y) \end{bmatrix}}_{\frac{\partial f(X, Y)}{\partial (r, \varphi)}} = \underbrace{\begin{bmatrix} \frac{\partial f}{\partial x}(X, Y) & \frac{\partial f}{\partial y}(X, Y) \end{bmatrix}}_{\frac{\partial f}{\partial (X, Y)}(X, Y)} \cdot \underbrace{\begin{bmatrix} \frac{\partial X}{\partial r} & \frac{\partial X}{\partial \varphi} \\ \frac{\partial Y}{\partial r} & \frac{\partial Y}{\partial \varphi} \end{bmatrix}}_{\frac{\partial (X, Y)}{\partial (r, \varphi)}}$$

$$g(r, \varphi) := \begin{bmatrix} X(r, \varphi) \\ Y(r, \varphi) \end{bmatrix}$$

$$f \circ g = f(X, Y)$$



$$\left[ \frac{\partial f(x,y)}{\partial r} \quad \frac{\partial f(x,y)}{\partial \varphi} \right] = \left[ \cos(y-x^2) + 2x^2 \sin(y-x^2) \quad -x \sin(y-x^2) \right] \cdot \underbrace{\begin{bmatrix} \cos \varphi & -r \sin \varphi \\ \sin \varphi & r \cos \varphi \end{bmatrix}}_{\frac{\partial (x,y)}{\partial (r,\varphi)}} = \frac{\partial f}{\partial (r,\varphi)}(r,\varphi)$$


$$\begin{aligned} x &= r \cos \varphi \\ y &= r \sin \varphi \end{aligned}$$

$$f(x,y) = x \cos(y-x^2)$$

$$\frac{\partial f}{\partial x} = \cos(y-x^2) + 2x^2 \sin(y-x^2)$$

$$\frac{\partial f}{\partial y} = -x \sin(y-x^2)$$

Kettenregel in Kl. (A)  $a_1, a_2 \in \mathbb{R}$




$$A = g(a_1 x_1 + a_2 x_2)$$

$$B = g(b_1 x_1 + b_2 x_2)$$

$$C = g(c_1 A + c_2 B)$$

$g$  könnte z.B.  $g(t) = \ln(1+e^t)$



$$A = A(a_1, a_2; x_1, x_2)$$

$$B = B(b_1, b_2; x_1, x_2)$$

$$C = C(a_1, a_2, b_1, b_2, c_1, c_2; x_1, x_2).$$

$$X^{(i)} = (x_1^{(i)}, x_2^{(i)}) \text{ mit } i = 1, \dots, N$$

Stichprobe, mit Labels  $L^{(i)} \in \mathbb{R}$   
(der gewünschte Output).

Training ist:

$$\min_{a_1, a_2, b_1, b_2, c_1, c_2 \in \mathbb{R}} \sum_{i=1}^N \left( \overbrace{C(a_1, a_2, b_1, b_2, c_1, c_2; x_1^{(i)}, x_2^{(i)})}^{\text{Gewichte}} - \overbrace{L^{(i)}}^{C^{(i)}} \right)^2$$

Loss function


$$f(a_1, a_2, b_1, b_2, c_1, c_2)$$

Wir brauchen  $\frac{\partial f}{\partial (a_1, a_2, b_1, b_2, c_1, c_2)}$  um

einen Gradienten-Abstieg zum Optimieren zu nutzen.

$$\frac{\partial f}{\partial a_1} = \sum_{i=1}^N \frac{\partial}{\partial a_1} (C^{(i)} - L^{(i)})^2 = \sum_{i=1}^N 2(C^{(i)} - L^{(i)}) \cdot \frac{\partial C^{(i)}}{\partial a_1}$$


$$\begin{aligned}
\frac{\partial C}{\partial a_1} &= \frac{\partial}{\partial a_1} g(c_1 A + c_2 B) \\
&= g'(c_1 A + c_2 B) \cdot \frac{\partial (c_1 A + c_2 B)}{\partial a_1} \\
&= g'(c_1 A + c_2 B) \cdot c_1 \frac{\partial A}{\partial a_1} \\
&= g'(c_1 A + c_2 B) \cdot c_1 \frac{\partial}{\partial a_1} g(a_1 x_1 + a_2 x_2) \\
&= g'(c_1 A + c_2 B) \cdot c_1 g'(a_1 x_1 + a_2 x_2) \cdot \frac{\partial (a_1 x_1 + a_2 x_2)}{\partial a_1} \\
&= g'(c_1 A + c_2 B) \cdot c_1 g'(a_1 x_1 + a_2 x_2) \cdot x_1
\end{aligned}$$



$$\frac{\partial C}{\partial a_2}, \quad \frac{\partial C}{\partial b_1}, \quad \frac{\partial C}{\partial b_2} \quad - \text{Analog.}$$


$$\begin{aligned}
\frac{\partial C}{\partial c_1} &= \frac{\partial}{\partial c_1} g(c_1 \cdot A + c_2 \cdot B) = \\
&= g'(c_1 A + c_2 B) \cdot \frac{\partial (c_1 A + c_2 B)}{\partial c_1} \\
&= g'(c_1 A + c_2 B) \cdot A
\end{aligned}$$

Komplizierteres  
Beispiel



$$\begin{aligned}
 \frac{\partial F}{\partial a_1} &= \frac{\partial}{\partial a_1} g(e_1 C + e_2 D) \\
 &= g'(e_1 C + e_2 D) \cdot \frac{\partial}{\partial a_1} (e_1 C + e_2 D) \\
 &= g'(e_1 C + e_2 D) \cdot \left( e_1 \frac{\partial C}{\partial a_1} + e_2 \frac{\partial D}{\partial a_1} \right)
 \end{aligned}$$

Noch ein etwas komplizierteres  
Beispiel



$$A_1 = g(a_{11}x_1 + \dots + a_{1,1000}x_{1000})$$

$$\frac{\partial C}{\partial a_{11}} = g' \left( \sum_{i=1}^{10^6} c_i B_i \right) \cdot \left( \sum_{i=1}^{10^6} c_i \frac{\partial B_i}{\partial a_{11}} \right)$$

$$= g' \left( \sum_{i=1}^{10^6} c_i B_i \right) \cdot \sum_{i=1}^{10^6} c_i \frac{\partial}{\partial a_{11}} g \left( \sum_{j=1}^{10^6} b_{ij} A_j \right)$$

$$= g' \left( \sum_{i=1}^{10^6} c_i B_i \right) \sum_{i=1}^{10^6} c_i g' \left( \sum_{j=1}^{10^6} b_{ij} A_j \right) b_{i1} \frac{\partial A_1}{\partial a_{11}}$$

$$= g' \left( \sum_{i=1}^{10^6} c_i B_i \right) \sum_{i=1}^{10^6} c_i g' \left( \sum_{j=1}^{10^6} b_{ij} A_j \right) b_{i1} g' \left( \sum_{k=1}^{10^6} a_{1k} x_k \right) x_1$$